

SUSTENTACION PROYECTO 3

Introducción a la Inteligencia Artificial

Motor de Inferencia por Enumeración con Redes Bayesianas

Luis Felipe Gutiérrez

Mayo de 2025

1. Cambios realizados en archivos .csv

En primer lugar, se creó un nuevo archivo en la carpeta de "ejemplo-clase" llamado "dia.csv", en donde se crearon 2 columnas, una con el día y otra con su respectiva probabilidad. Luego se asignaron los valores a cada columna, siendo "lunes a miercoles", "jueves" "viernes a domingo". Se les asignó una probabilidad de 0.3, 0.3 y 0.4, respectivamente. Luego se modificó el archivo "appointment.csv" con el formato de train, dia, appointment, probabilidad. Por último, se agregó la relación en el grafo entre dia y appointment, para que se pueda hacer la conexión posterior.

2. Ecuación a mano

La ecuación se hizo mirando las variables ocultas que tenían las probabilidades ya descritas en los demás archivos. Luego se planteó el cociente de ambas sumatorias, en donde se toman en cuenta todas las posibilidades de rain y appointment, con el fin de sacar todos los valores correspondientes. Luego se hizo el cálculo a mano de cada parte del numerador y del denominador, para dar como resultado 0,6 (que es una variable aleatoria porque es un valor entre 0 y 1).

3. Ejecución del código

$$\begin{aligned}
 & \star P(\text{Appointment} = \text{"attend"} \mid T_{\text{rain}} = \text{"delayed"}, D_{\text{ia}} = \text{"lunes a miércoles"}) \\
 & \star \text{Variables ocultas} \rightarrow \text{rain, maintenance} \\
 & \rightarrow \star \star \frac{\sum P(\text{Appointment} = \text{"attend"}, T_{\text{rain}} = \text{"delayed"}, D_{\text{ia}} = \text{"lunes a miércoles"}, \text{rain}, \text{maintenance})}{\sum P(\text{Appointment}, T_{\text{rain}} = \text{"delayed"}, D_{\text{ia}} = \text{"lunes a miércoles"}, \text{rain}, \text{maintenance})} \\
 & \rightarrow \star = P(\text{rain}) = P(\text{maintenance} \mid \text{rain}) \times P(T_{\text{rain}} = \text{"delayed"} \mid \text{rain}, \text{maintenance}) \times P(D_{\text{ia}} = \text{"lunes a miércoles"}) \times \\
 & \quad P(\text{Appointment} = \text{"attend"}, T_{\text{rain}} = \text{"delayed"}, D_{\text{ia}} = \text{"lunes a miércoles"}) \\
 & \rightarrow \star \text{rain} = \text{"none"} \rightarrow \text{maintenance} = \text{"yes"} = 0.7 \times 0.4 \times 0.2 \times 0.3 \times 0.6 = 0.01008 \\
 & \quad \rightarrow \text{maintenance} = \text{"no"} = 0.7 \times 0.6 \times 0.1 \times 0.3 \times 0.6 = 0.00756 \\
 & \text{rain} = \text{"light"} \rightarrow \text{maintenance} = \text{"yes"} = 0.2 \times 0.2 \times 0.4 \times 0.3 \times 0.6 = 0.00288 \\
 & \quad \rightarrow \text{maintenance} = \text{"no"} = 0.2 \times 0.8 \times 0.3 \times 0.3 \times 0.6 = 0.00864 \\
 & \text{rain} = \text{"heavy"} \rightarrow \text{maintenance} = \text{"yes"} = 0.1 \times 0.1 \times 0.6 \times 0.3 \times 0.6 = 0.00108 \\
 & \quad \rightarrow \text{maintenance} = \text{"no"} = 0.1 \times 0.9 \times 0.5 \times 0.3 \times 0.6 = 0.00810 \\
 & 0.01008 + 0.00756 + 0.00288 + 0.00864 + 0.00108 + 0.00810 = 0.03834 \\
 & \rightarrow \star = 0.7 \times 0.6 \times (0.4 \times 0.2 + 0.6 \times 0.1) + 0.2 \times 0.3 \times (0.2 \times 0.4 + 0.8 \times 0.3) + 0.1 \times 0.3 \times (0.1 \times 0.6 + 0.9 \times 0.5) = 0.0639 \\
 & \Rightarrow \star = \frac{0.03834}{0.0639} = 0.6
 \end{aligned}$$

Figura 1: Ecuación hecha a mano

```

PS C:\Users\elpip\Documentos\GitHub\Proyectos_IA\Proyecto_3> & C:/Python313/python.exe c:/Users/elpip/Documentos/GitHub/Proyectos_IA/Proyecto_3/proyecto_3.py
Estructura de la red bayesiana:
Nodos: ['rain', 'maintenance', 'train', 'appointment', 'dia']
Aristas:
  rain → maintenance
  rain → train
  maintenance → train
  train → appointment
  dia → appointment

Trazando P(appointment | train=delayed, dia=lunes a miercoles)

Para appointment = attend:
  Combinación: {'rain': 'none', 'maintenance': 'yes'}
    P(rain=none | padres) = 0.70000 * P(maintenance=yes | padres) = 0.40000 * P(train=delayed | padres) = 0.20000 * P(appointment=attend | padres) = 0.60000 * P(dia=lunes a miercoles | padres) = 0.30000
    → Producto total: 0.01080000

  Combinación: {'rain': 'none', 'maintenance': 'no'}
    P(rain=none | padres) = 0.70000 * P(maintenance=no | padres) = 0.60000 * P(train=delayed | padres) = 0.10000 * P(appointment=attend | padres) = 0.60000 * P(dia=lunes a miercoles | padres) = 0.30000
    → Producto total: 0.00756000

  Combinación: {'rain': 'light', 'maintenance': 'yes'}
    P(rain=light | padres) = 0.20000 * P(maintenance=yes | padres) = 0.20000 * P(train=delayed | padres) = 0.40000 * P(appointment=attend | padres) = 0.60000 * P(dia=lunes a miercoles | padres) = 0.30000
    → Producto total: 0.00288000

  Combinación: {'rain': 'light', 'maintenance': 'no'}
    P(rain=light | padres) = 0.20000 * P(maintenance=no | padres) = 0.80000 * P(train=delayed | padres) = 0.30000 * P(appointment=attend | padres) = 0.60000 * P(dia=lunes a miercoles | padres) = 0.30000
    → Producto total: 0.00864000

  Combinación: {'rain': 'heavy', 'maintenance': 'yes'}

```

Figura 2: Salida de consola 1

```

  Combinación: {'rain': 'heavy', 'maintenance': 'no'}
    P(rain=heavy | padres) = 0.10000 * P(maintenance=no | padres) = 0.90000 * P(train=delayed | padres) = 0.50000 * P(appointment=attend | padres) = 0.40000 * P(dia=lunes a miercoles | padres) = 0.30000
    → Producto total: 0.00540000

Suma total (no normalizada) para miss: 0.02556000

Distribución sin normalizar: {'attend': 0.03834, 'miss': 0.02556}
Distribución normalizada:
  P(appointment=attend | evidencia) = 0.60000
  P(appointment=miss | evidencia) = 0.40000

Resultado de la inferencia:
P(appointment = attend) = 0.6000
P(appointment = miss) = 0.4000

```

Figura 3: Salida de consola 2